新型硬件 GPU 在 PostgreSQL 的应用

译者：朱君鹏，陈河堆

作者简介

Naju Mancheril，来自卡耐基梅隆大学。这是一篇介绍在 PostgreSQL 中应用新型硬件 GPU 提升排序性能的论文，是当前热门的数据库前沿技术研究领域。原论文名称为《GPU-based Sorting in PostgreSQL》。

译者简介

朱君鹏，华东师范大学博士研究生，个人兴趣主要集中在：新型硬件（GPU、RDMA、FPGA）等在数据库中的应用，架构设计与并行计算。

陈河堆，中兴通讯数据库平台负责人，曾参与和主导公司自研高性能内存数据库、分布式数据库和分布式缓存等系统的开发和设计，目前致力于 PostgreSQL 数据库的研究和推广。

摘要

尽管每个微处理器内核的晶体管数量在过去十年中有所增加，但复杂性的增加仅导致应用性能的适度增加。大多数性能改进可以追溯到技术扩展的更快时钟速率。虽然复杂的、广泛的、超标量核心提供更高的单线程性能，但它们通常不适合具有大量独立线程的应用程序。在后一种情况下，具有多个简单独立内核的多处理器可提供最佳性能[1]。本文不寻求解决哪种复杂程度更适合数据库管理系统的执行。相反，我们探索异构处理环境提供的优势。

具体来说，我们分析了使用 GPU 来帮助我们的排序操作所带来的性能改进。为此，我们将基于 GPU 的快速排序算法 GPUSort 集成到 PostgreSQL 数据库管理系统中。我们使用 GPUSort 来实现用于处理 SQL 语句中的 ORDER BY 子句的键指针排序。我们发现由于设置基于 GPU 的排序的通信开销，qsort()仍然是排序小关系的更快的选择。但是，当关系达到中等大小（大约 1MB）时，GPUSort 表现更好。

1. 概述

在过去十年中，每个微处理器内核的晶体管数量有所增加，但复杂性的增加仅导致应用性能的适度增加。大多数性能改进可以追溯到技术扩展的更快时钟速率。虽然更复杂的内核

提供更高的单线程性能，但它们通常不适合具有大量独立线程的应用程序。在后一种情况下，具有多个简单独立内核的多处理器可提供最佳性能[1]。本文不寻求解决哪种级别的复杂性更适合数据库管理系统。相反，我们探索异构处理环境提供的优势。特别是，虽然在通用 CPU 上执行我们的数据库管理系统，但我们分析了使用一个 GPU 来辅助排序操作可能提供的性能改进。

现代 GPU（图形处理单元）的结构与通用 CPU 非常不同。 GPU 针对一系列操作（比如纹理映射）进行了优化，这在 CPU 中是没有等效硬件支持的。它们的内存子系统也不同，因为除了板载视频内存之外，GPU 还必须管理到系统 RAM 的高速接口。然而，最令人吃惊的区别在于对并行性的硬件支持水平。虽然现代 GPU 的时钟频率仅为 400 MHz，但它可以有多达 20 个独立的流水线。每个时钟周期，有大量指令可以执行完毕[2]。

由于这种并行性，现代 GPUS 在原始 FLOPS（每秒浮点运算）方面甚至超过了高端 CPU。最近，在利用这种处理能力并用它来解决通用计算中出现的复杂问题方面已经做了很多工作[3]。一个这样的问题是排序。排序是现代数据库和数据挖掘系统中主要延迟的原因。这些系统通常简化为使用基于 CPU 的内存快速排序。在本文中，我们展示如果允许这些系统访问图形处理器，他们可以利用特别适合现代 GPU 功能的快速并行排序算法。

北卡罗来纳大学教堂山分校的GPUSort项目致力于设计和实现基于GPU的高效排序算法。我们使用的GPUSort实现通过使用OpenGL纹理映射操作将一个bitonic排序网络映射到GPU。排序算法还通过使用高速缓存有效的内存访问模式充分利用了图形卡的内存带宽。图 1 显示了使用一个第一代旧 NVIDIA GPU [4]在 3.4 GHz 奔腾 4 处理器系统上运行的 GPUSort 击败 qsort()。

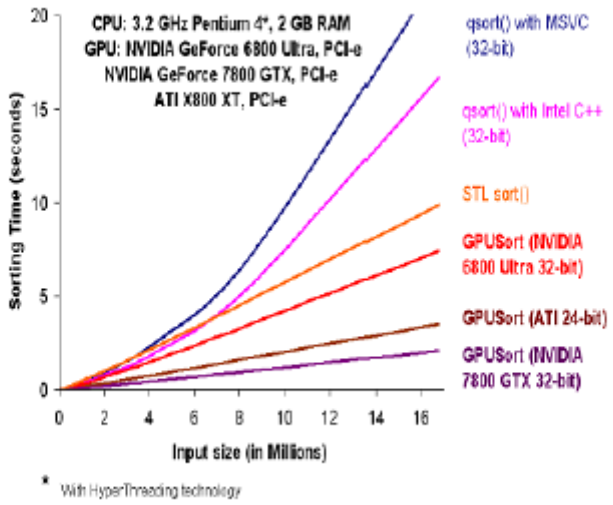

图 1 原始 GPUSort 和原始 qsort() [4]

我们通过将其与 PostgreSQL 数据库管理系统集成来探索 GPUSort 提供的改进。具体来说，我们使用它来实现用于处理 SQL 语句中的 ORDER BY 子句的键指针排序。我们发现由于将元组传递给图形卡的通信开销，qsort()仍然是排序小关系的更快选择。但是，当关系达到中等大小（大约 1MB）时，GPUSort 表现更好。

本文的其余部分的结构如下。第 2 节简要介绍了 Bitonic 排序网络。第 3 节讨论了我们修改过的 PostgreSQL 系统的体系结构。第 4 节包含我们实验评估的设置。第 5 节包含我们的实验结果和分析。最后，第 6 节包含我们的结论和未来工作的可能领域。

2. Bitonic 排序

Bitonic 排序（或 bitonic 归并排序）[5]是一种利用排序网络的快速排序算法。排序网络[6]是一个特殊的基于比较的并行排序过程，其中比较序列不依赖于数据[7] [8] [9]。这使得排序网络成为理想的并行化功能，甚至可能在硬件中实现。

假设有一个序列 $a = a_0$，....，a_{n-1}，其中 $a_i \in \{0,1\}$， $i = 0$，...，$n-1$，它称为 0-1 序列。如果在 0 和 1 比特系列之间最多包含两次变化，则该 0-1 序列称为 bitonic。即如果存在子序列长度 k，$m \in \{1, \ldots, n\}$，使得

$$a_0, \ldots, a_{k-1} = 0, a_k, \ldots, a_{m-1} = 1, a_m, \ldots, a_{n-1} = 0$$

或

$$a_0, \ldots, a_{k-1} = 1, a_k, \ldots, a_{m-1} = 0, a_m, \ldots, a_{n-1} = 1$$

Bitonic 排序网络有两个主要组成部分：比较器网络和归并网络。这些组件是递归定义的。如果 B_n 是一个能对 n 位数进行排序的比较器网络，则有：

$$B_n(a) = b_0, \ldots, b_{n/2-1}\ c_0, \ldots, c_{n/2-1}$$

其中，对于 i，$j \in \{1, \ldots, n/2-1\}$，有 $b_i \leqslant c_j$，而且，$b_0, \ldots, b_{n/2-1}$ 和 $c_0, \ldots, c_{n/2-1}$，每个都是 bitonic。归并网络将这两个有序的 bitonic 序列组合成一个。现在对 n 位进行排序成为一个标准的分而治之算法，包括拆分和排序阶段，然后跟随一个归并阶段。

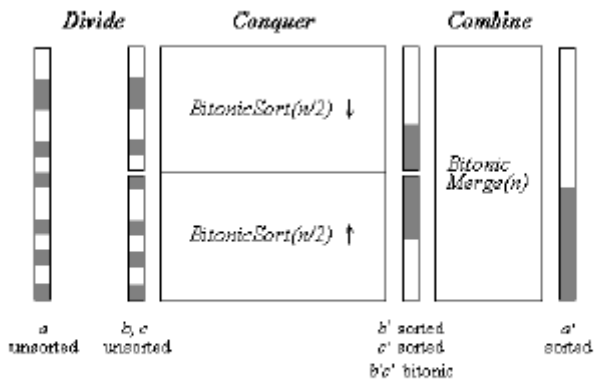

(a) Bitonic Sort Network

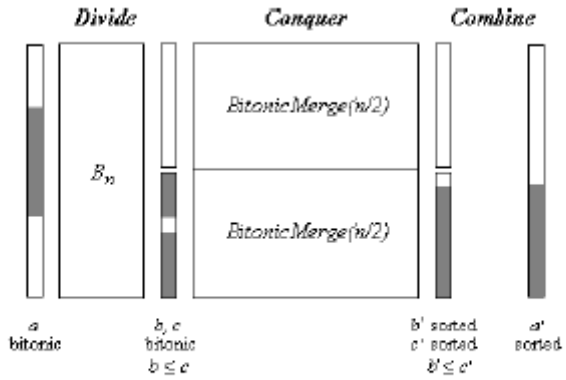

(b) Bitonic Merge Network

图 2 Bitonic 排序[10]

每个排序和归并迭代称为一个阶段。通过使用 n 个独立处理器的阵列，bitonic 排序允许我们在 O（log n）阶段内对 n 个元素进行排序，且每个阶段只需 O（log n）个步骤。总运行时间为 O（$\log^2$ n），远远优于 quicksort [11]提供的 O（n log n）时间。

GPUSort 使用 OpenGL 纹理映射函数将 32 位浮点比较器网络映射到我们图形处理器的 20 条流水线上。因此，我们可以在每个 400 MHz 周期中执行完大约 20 个比较指令，与之鲜明对比是，每个周期 3.0GHz CPU 只能执行完 2-3 个指令。

3．数据库体系结构

PostgreSQL 中的排序操作是使用 tuplesort 模块实现的。尽管所有数据库操作符都具有迭代器风格的接口（open，next，close），但正确排序需要访问所有输入元组。因此，

tuplesort 接口要求 sort 操作符代码从其输入流中对每个元组调用 puttuple（），然后调用 performsort（）进行实际排序，最后在每次 next（）调用时调用 gettuple（），直到每个元组都被有序获取。

peformsort（）函数可以以两种方式之一工作。对于小数据集（小于 1MB），它构造一个元组指针的纯内存数组，定义一个比较器函数来对两个元组指针进行排序，然后调用 libC 的 qsort（）函数。对于较大的数据集，它使用带堆排序的外部排序来构建有序的执行系列。

图 3 显示了我们所做修改的高层次描述。一旦我们能够从元组指针中抽取浮点键，我们就能够构造自己的浮点数偶对数组，并将这个纯内存数组直接传递给 GPUSort 代码。完成之后，使用有序的键指针数组将原始的元组数组置换为有序顺序。

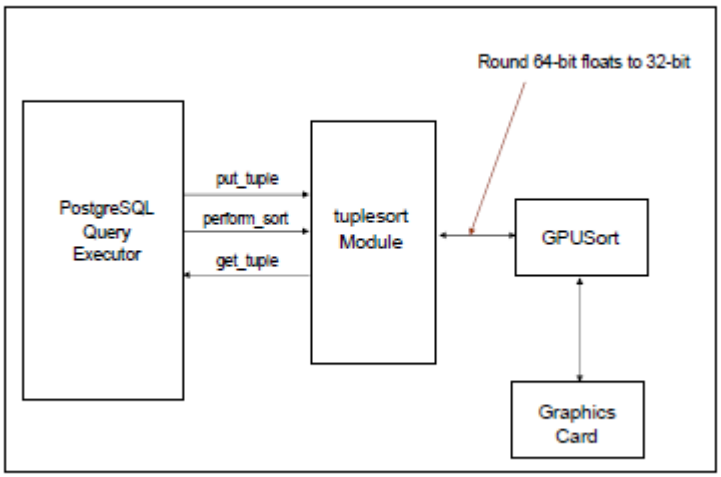

图 3 PostgreSQL 排序体系架构

尽管 SQL 将 FLOAT 定义为 4 字节浮点值，但 PostgreSQL 内部使用 64 位（双）数据类型来表示它。只可惜 GPUSort 当前只支持 16 位和 32 位浮点数，否则这不算什么问题。出于这个原因，在应用 GPUSort 之前，我们必须将每个 double 值舍入到最接近的 float 值。此舍入过程不会更改结果元组的集合，因为在我们的工作负载中使用的元组不会使用超过几位数的精度。反而，在评估最终实现时，应牢记舍入的代价。完全采用 GPUSort 的任何系统要么使用 32 位浮点数，要么获取支持 64 位键值的 GPUSort 版本。

另一个问题是我们的 GPUSort 版本似乎是专门为 32 位机器设计的。因此，即使我们将 FLOAT32 指针偶对的数组传递给排序例程，OpenGL 代码也假设每个偶对的总大小为 8 个字节。我们通过传入 FLOAT32 偏移偶对数组来解决这个问题：我们传递了每个元素在元组数组中的

偏移量，而不是每个元素的绝对地址。由于偏移量是 32 位数，我们仍然可以对最多 40 亿个元组的数组进行排序，但我们希望在将来的工作中消除这种限制。

4. 实验设置

4.1 硬件

所有的开发和评估都是在具有 2048KB 缓存和超线程的 3.0GHz Intel（R）Pentium（R）4 CPU 上完成的。系统配备 1GB 主内存。使用的显卡是 eVGA Geforce 7800GT，配备 256MB RAM。核心 GPU 速度为 400 MHz，板载内存运行速度为 500 MHz。该卡使用 x16 PCI-Express 接口，最大额定内存带宽为 54.4GB /秒[2]。

4.2 软件

我们的排序是来自北卡罗来纳大学教堂山分校的 GPUSort 项目的 GPUSort 1.0。我们将它集成到 PostgreSQL 8.2devel 中。所有评估都在 Fedora Core 第 4 版上完成，Linux 内核版本为 2.6.11-1.1369_FC4smp，针对 x86_64 进行了优化。

4.3 工作负载

我们使用一个微基准测试风格的评估，因为我们只关心测量排序操作符的性能。实验使用如下表模式：

```
TABLE vals(x FLOAT, y FLOAT)
```

我们在这个表中填充了一百万个元组，这些元组在 0.0 到 100.0 之间随机均匀生成。我们所有的查询都来自以下模板：

```
SELECT * FROM vals
WHERE y < y0
ORDER BY y
```

这个简单的查询总是产生如图 4 所示的双运算符查询计划。

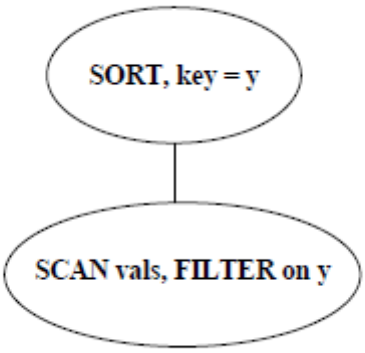

图 4 微基准测试查询计划

由于基表中的元组是随机均匀生成的，我们可以通过改变 y0 的值来控制 SCAN 运算符的选择性。例如，通过将 y0 设置为 10.0，我们可以执行一次对（10.0 / 100.0）•100 万= 100,000 个元组的排序。

在我们的实验中，我们改变了关系大小以及图形卡上 GPUSort 代码使用的视频内存量。另一个可能调节的参数是元组大小。但是，这不会影响排序成本，因为 PostgreSQL 实现了键指针排序。无论每个元组的大小如何，当我们执行比较和交换时，我们只会移动浮点数和字大小的指针（或者对于 GPUSort 来说是一个 32 位的偏移）。

5. 实验结果

5.1 大输入

我们比较了三种不同排序算法的执行时间：默认的 PostgreSQL 外部排序，PostgreSQL 内部排序和 GPUSort。图 5 显示了这三种算法在大输入规模下的性能。 “堆排序”是 PostgreSQL 外部排序算法。它使用堆排序来创建每个 1MB 的有序执行系列，然后将它们归并在一起。 “qsort”表示内部排序算法，它实际上只是对 libC qsort（）函数的调用。出于测量目的，我们将 qsort 使用的内存量增加到 1GB。 GPUSort 256MB 显示使用 256 MB 视频卡的 GPUSort 运行时间。

需要注意的一点是，“堆排序”的执行时间不随输入大小单调增加。由于该算法基于分而治之思想，因此当输入可以被均分多次时，它将表现得更好。虽然在图 5 中很难看得出来，但 GPUSort 也表现出这种行为特征。这在图 6 中应该看得更清楚，它显示了 GPUSort 如何随

着更大输入而按比例增长[1]。

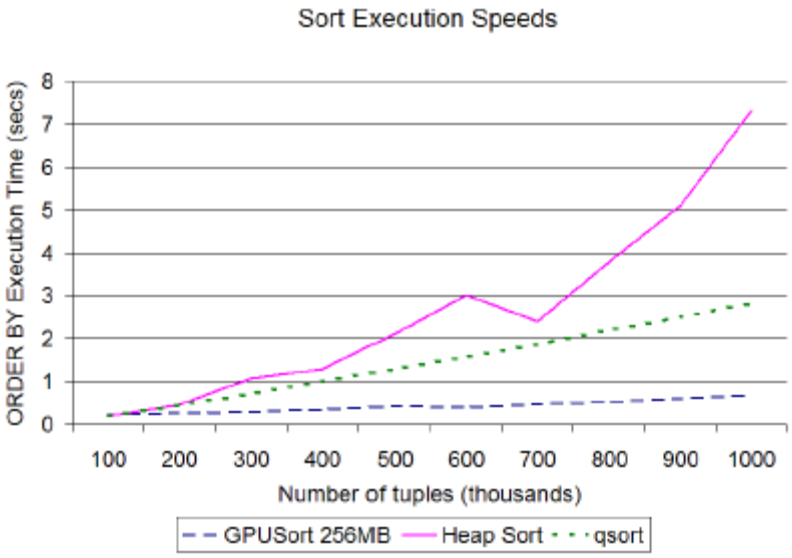

图 5 ORDER BY 子句执行时间

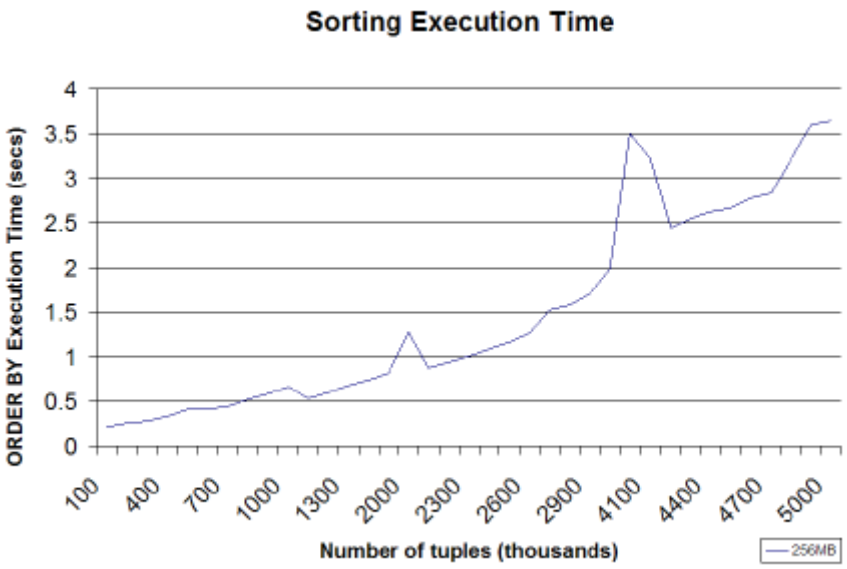

图 6 GPUSort ORDER BY 子句执行时间

每当元组数量跨过一个 2 的幂次方时，我们就会看到排序时间的一次下降。我们在 50 万、100 万、200 万和 400 万个元组时分别看到了这个现象。对 420 万个元组进行排序所花费的时间比对 400 万个元组进行排序所花费的时间要少。此行为实际上是 GPUSort 库的实现方式。在应用纹理映射例程之前，GPUSort 会将元组编组为内部矩阵。当前实现不会对完

全在 GPU 上对数组进行排序，它将产生非 2 的幂次方大小的矩阵。相反，它采用比输入数组尺寸小的 2 的最大幂，在 GPU 上对结果矩阵进行排序，使用 qsort（）对剩余数据进行排序，最后将两个流归并在一起。由于涉及到额外的 CPU 使用开销，代码运行在非 2 的幂次方大小的数组上执行得更慢[4]。

好消息是即使我们可能会看到执行时间的这种变化，但是，当数据集变大时，GPUSort 总是比 qsort（）快。即使查询优化器必须决定使用哪种排序算法，也无需专门处理这些 2 的幂次方问题。事实上，对于大型（大于 1MB）数据集，GPUSort 的执行速度始终是内部快速排序的 4 倍。

5.2 小输入

我们已经看到 GPUSort 的性能取决于它需要多少 CPU 支持。尽管图 5 显示 GPUSort 的性能优于基于 CPU 的替代方案，但这些测量是通过大输入来完成的，这里的执行时间主要由排序时间来决定。情况并非总是如此。我们可以将应用程序用于执行 GPUSort 的总时间分为四个部分：

$$T_{sort} = T_{array_build} + T_{network_build} + T_{transfer} + T_{GPU} + T_{CPU}$$

T_{sort} 是总排序时间，T_{array_build} 是使用 CPU 构建键偏移数组所需的时间，$T_{network_build}$ 是在 GPU 上构建一个 bitonic 排序网络所需的时间，$T_{transf\ er}$ 是将数据传输到 GPU 所需的时间。T_{GPU} 是对显卡进行排序所需的时间，而 T_{CPU} 是 qsort（）剩余数据和归并两个有序流所需的任何额外时间。

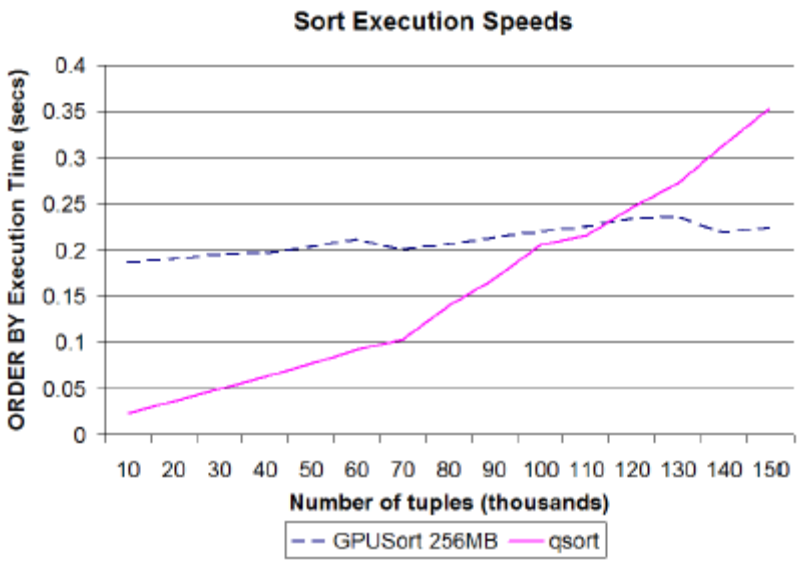

图 7 ORDER BY 子句处理时间

创建单独的键指针数组+T_{array_build}+创建排序网络+$T_{network_build}$+将元组传递到图形卡 $T_{transfer}$ 的开销对于排序小关系而言可能太高。图 7 展示了这种情况。当要排序的元组数量小于 10 万时，qsort（）实际上是更快的选项。

5.3 显存大小

GPUSort 必须在显卡的视频内存中保留空间，以存储将要被排序的矩阵。通过改变 GPUSort 对总视频内存大小的估算，我们可以控制它生成的矩阵的大小。我们很想知道当 GPUSort 拥有处理功能较弱的图形处理器时的性能表现。图 8 显示了此功能伸缩时的结果。

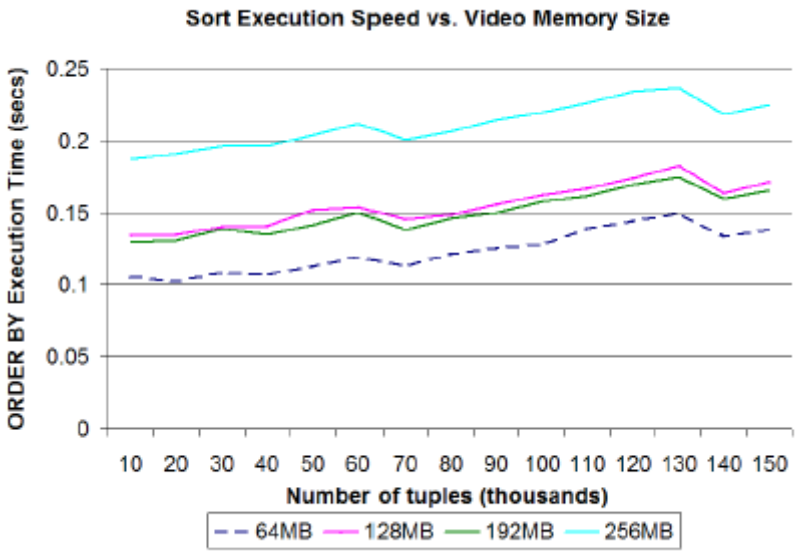

图 8 改变视频内存

该图表中的奇怪结果是 256MB 显卡表现最差。256MB 是我们使用的视频图形卡的总内存容量。最初，我们认为这种糟糕的性能可能是视频内存和系统 RAM 之间抖动的结果。毕竟，PostgreSQL 必须与 XWindows 和其他可能正在运行的应用程序共享显卡。然而，通过运行更多测试，我们可以找到更简单的解释。回想一下 GPUSort 的执行时间分解：

$$T_{sort} = T_{array_build} + T_{network_build} + T_{transfer} + T_{GPU} + T_{CPU}$$

事实证明，$T_{network_build}$ 根据 GPUSort 将使用的视频内存量成比例进行缩放。为了构建我们

的排序网络，我们必须在显卡上分配内存，决定在哪里放置我们的矩阵，并承担在系统 RAM 和显卡之间建立未来传输所涉及的任何开销。事实证明，没有必要为每次排序构建一个新的排序网络。我们可以“预先计算”卡上的排序网络，并在每次排序中重复使用它。其结果，$T_{network_build}$ 被摊销了，而我们看到了更合理的执行时间：

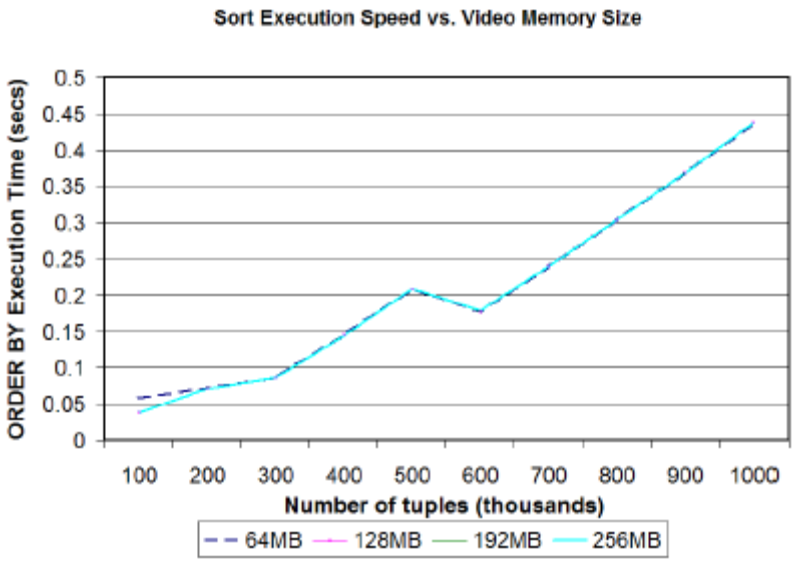

图 9 改变视频内存与重用排序网络

图 9 显示，对于大型数据集，GPUSort 非常之快，以至于它实际并在乎 GPU 可以访问多少视频内存。其性能仅受 GPU 速度和可用于将数据从系统 RAM 传输到视频 RAM 的带宽的限制。根据这些参数测量性能是未来工作的主题。

6. 结论

本文通过将其与 PostgreSQL 数据库管理系统集成，探讨了 GPUSort（一种基于 GPU 的快速排序算法）所提供的改进。具体来说，它被用来实现用于处理 SQL 语法 ORDER BY 子句的键指针排序。我们发现由于将元组传输到显卡所涉及的开销，qsort（）仍然是较小关系的更快选择。然而，当关系的大小变为 1 MB 级别时，GPUSort 会更快。

现代 GPU 不会取代通用 CPU，但其独特的并行流水线设计给予它们巨大潜力，用于提升计算和内存受限程序的性能。即使是 64MB 显卡（其售价低于 100 美元），也可以比传统的基于 CPU 的 qsort（）提供很大改进。

GPU 提供的好处只会随着每张卡内流水线的速度和数量而增加。随着 PCI Express 的出现，总线传输变得越来越不成为瓶颈，这种技术提供了两倍于旧 AGP-8x 接口的独立传输通道。这些进步促成了许多项目的创建，特别是 GPGPU 项目，他们完全致力于设计和实现用于通用应用软件编码的 GPU 协处理器库。虽然基于图形库的应用程序可能更难开发，但它们最终会胜出：这些库提供的性能提升将超过复杂性的增加。

数据库系统不是唯一在不同执行阶段具有非常不同资源需求的应用程序。在“正常”执行期间，存在大量指令级并行性。为了执行这样的程序，一个多发的超标量 CPU 提供了最佳性能。但是，当应用程序需要执行一些计算密集型操作（如排序）时，大量独立流水线提供了最佳性能。最后，内核复杂性的最佳选择实际上可能是“以上全部”：同时具有高和低复杂度内核的异构芯片多处理器，可以在程序执行的不同阶段分别激活[1]。

引用

[1] R. Kumar, D. Tullsen, N. Jouppi, and P. Ranganathan. Heterogeneous chip multiprocessors. IEEE Computer, 38, No. 11:32–38, 2005.

[2] NVIDIA Corporation. NVIDIA GeForce 7800 GPUs Specifications.

[3] GPGPU Project. http://www.gpgpu.org.

[4] GPUSort Project. GPUSort Documentation.

[5] K.E. Batcher. Sorting networks and their applications. volume 32, pages 307–314, 1968.

[6] T.H. Cormen, C.E. Leiserson, and R.L. Rivest. Introduction to Algorithms. MIT Press / McGraw-Hill, Cambridge, Massachusetts, 1990.

[7] C.D. Thompson and H.T. Kung. Sorting on a meshconnected parallel computer. Communications of the ACM, 20 4:263–271, 1977.

[8] H.W. Lang, M. Schimmler, H. Schmeck, and H. Schroder. Systolic sorting on a mesh-connected network. IEEE Transactions on Computers, C-34, 7:652–658, 1985.

[9] C.P. Schnorr and A. Shamir. An optimal sorting algorithm for mesh-connected computers. pages 255–261, 1986.

[10] Institut fur Medien Informatik und Technische Informatik. Sequentielle und parallele Sortierverfahren: Bitonic Sort.

[11] Randima Fernando. GPU Gems: Programming Techniques, Tips, and Tricks for Real-Time Graphics. Pearson Education, Boston, Massachusetts, 2003.

文章链接：https://pdfs.semanticscholar.org/869f/beb4db447174d4c6a475e942a2607465a410.pdf